


2 图像去畸变(3 分, 约 1 小时)



```
// TODO 按照公式, 计算点(u,v)对应到畸变图像中的坐标(u_distorted, v_distorted) (~6 lines)
// start your code here
double x = (u-cx)/fx;
double y = (v-cy)/fy;
double r = x * x + y * y;
u_distorted = x * (1 + k1 * r + k2 * r * r) + 2 * p1 * x * y + p2 * (r + 2 * x * x);
v_distorted = y * (1 + k1 * r + k2 * r * r) + p1 * (r + 2 * y * y) + 2 * p2 * x * y;
u_distorted = fx * u_distorted + cx;
v_distorted = fy * v_distorted + cy;
// end your code here
```

3 双目视差的使用(2 分, 约 1 小时)

Point Cloud Viewer



```
// start your code here (~6 lines)
// 根据双目模型计算 point 的位置
double x = (u - cx) / fx;
double y = (v - cy) / fy;
unsigned char disparity_value = disparity.at<uchar>(v,u);
double z = fx * d / disparity_value;
point[0] = x * z;
point[1] = y * z;
point[2] = z;
pointcloud.push_back(point);
// end your code here
```

4 矩阵运算微分(2 分, 约 1.5 小时)

设变量为 $\mathbf{x} \in \mathbb{R}^N$, 那么:

1. 矩阵 $\mathbf{A} \in \mathbb{R}^{N \times N}$, 那么 $d(\mathbf{Ax})/d\mathbf{x}$ 是什么?

$$\mathbf{Ax} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n \end{bmatrix} = \begin{bmatrix} (\mathbf{Ax})_1 \\ \vdots \\ (\mathbf{Ax})_n \end{bmatrix}$$

$$\text{则 } \frac{d\mathbf{Ax}}{d\mathbf{x}} = \begin{bmatrix} \frac{d(\mathbf{Ax})_1}{d\mathbf{x}} \\ \vdots \\ \frac{d(\mathbf{Ax})_n}{d\mathbf{x}} \end{bmatrix} = \begin{bmatrix} \frac{d(\mathbf{Ax})_1}{dx_1} & \cdots & \frac{d(\mathbf{Ax})_1}{dx_n} \\ \vdots & \ddots & \vdots \\ \frac{d(\mathbf{Ax})_n}{dx_1} & \cdots & \frac{d(\mathbf{Ax})_n}{dx_n} \end{bmatrix} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \mathbf{A}$$

2. 矩阵 $\mathbf{A} \in \mathbb{R}^{N \times N}$, 那么 $d(\mathbf{x}^T \mathbf{Ax})/d\mathbf{x}$ 是什么?

这等于是一个标量对向量求导问题。其中 $\mathbf{x}^T \mathbf{Ax} = \sum_i^n \sum_j^n A_{ij} x_j x_i$

$$\frac{d(\mathbf{x}^T \mathbf{Ax})}{d\mathbf{x}} = \begin{bmatrix} \frac{\partial \sum_i^n \sum_j^n A_{ij} x_j x_i}{\partial x_1} \\ \vdots \\ \frac{\partial \sum_i^n \sum_j^n A_{ij} x_j x_i}{\partial x_k} \\ \vdots \\ \frac{\partial \sum_i^n \sum_j^n A_{ij} x_j x_i}{\partial x_n} \end{bmatrix}$$

当一个变量多次出现时, 可以分别对每次出现求导, 再求和, 则上式分别对 x_j, x_i 求导

$$= \begin{bmatrix} \sum_i^n A_{i1} x_i + \sum_j^n A_{1j} x_j \\ \vdots \\ \sum_i^n A_{ik} x_i + \sum_j^n A_{kj} x_j \\ \vdots \\ \sum_i^n A_{in} x_i + \sum_j^n A_{nj} x_j \end{bmatrix} = [\mathbf{Ax} \quad + \quad \mathbf{A}^T \mathbf{x}]$$

3. 证明: $\mathbf{x}^T \mathbf{Ax} = \text{tr}(\mathbf{Axx}^T)$.

首先上题证明 $d(\mathbf{x}^T \mathbf{Ax}) = \mathbf{Ax} + \mathbf{A}^T \mathbf{x}$

这里求 $d(\text{tr}(\mathbf{Axx}^T)) = \text{tr}(d(\mathbf{Axx}^T))$

$$\begin{aligned} &= \text{tr}(d\mathbf{A} * \mathbf{xx}^T + \mathbf{A} * d\mathbf{x} * \mathbf{x}^T + \mathbf{Ax} * d\mathbf{x}^T) \\ &= \text{tr}(\mathbf{A} * d\mathbf{x} * \mathbf{x}^T) + \text{tr}(\mathbf{Ax} * d\mathbf{x}^T) \\ &= \text{tr}(\mathbf{x}^T \mathbf{A} d\mathbf{x}) + \text{tr}((\mathbf{Ax}(d\mathbf{x})^T)^T) \\ &= \text{tr}(\mathbf{x}^T \mathbf{A} d\mathbf{x}) + \text{tr}(\mathbf{x}^T \mathbf{A}^T d\mathbf{x}) \\ &= \text{tr}((\mathbf{x}^T \mathbf{A} + \mathbf{x}^T \mathbf{A}^T) d\mathbf{x}) \end{aligned}$$

$$\begin{aligned}
 &= (X^T A + X^T A^T)^T \\
 &= A^T X + A X
 \end{aligned}$$

5 高斯牛顿法的曲线拟合实验 (3 分, 约 2 小时)

```
xin@ubuntu16:~/VSLAM-course/vSLAM-course/Ch4/homework/SLAM/L4/code/build$ ./gaussnewton
total cost: 3.19575e+06
total cost: 376785
total cost: 35673.6
total cost: 2195.01
total cost: 174.853
total cost: 102.78
total cost: 101.937
total cost: 101.937
total cost: 101.937
total cost: 101.937
total cost: 101.937
total cost: 101.937
total cost: 101.937
cost: 101.937, last cost: 101.937
estimated abc = 0.890912, 2.1719, 0.943629
```

```
for (int i = 0; i < N; i++) {
    double xi = x_data[i], yi = y_data[i]; // 第i个数据点
    // start your code here
    double error = 0; // 第i个数据点的计算误差
    error = yi - exp(ae * xi * xi + be * xi + ce); // 填写计算error的表达式
    Vector3d J; // 雅可比矩阵
    J[0] = -exp(ae * xi * xi + be * xi + ce) * xi * xi; // de/da
    J[1] = -exp(ae * xi * xi + be * xi + ce) * xi; // de/db
    J[2] = -exp(ae * xi * xi + be * xi + ce); // de/dc

    H += J * J.transpose(); // GN近似的H
    b += -error * J;
    // end your code here

    cost += error * error;
}

// 求解线性方程 Hx=b, 建议用ldlt
// start your code here
Vector3d dx;
// JJ^T * delta X = -J * f(x)
dx = H.ldlt().solve(b);
// end your code here
```

6 * 批量最大似然估计 (2 分, 约 2 小时)

1. 可以定义矩阵 H , 使得批量误差为 $e = z - Hx$ 。请给出此处 H 的具体形式。

在此系统中, v 为两帧之间的位移变量, x 为位移, 而且 x 是直接观测。

我们的观测 z 是 $\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ y_1 \\ y_2 \\ y_3 \end{bmatrix}$, 则我们要有一个 H 矩阵把状态量 $x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix}$ map (映射) 到观测空间。

最小二乘问题就是找到使得映射结果最接近观测的状态量 x (映射结果和观测的误差最小)。而这种误差包括 v 的误差, 即我们通过相邻帧 $x_1 - x_0$ 的得到的 v 和实际 v 的误差: $\text{error} = v_{\text{observed}} - (x_k - x_{k-1})$ 以及我们通过前一帧预测的下一帧的位置 x_1 和直接观测到的 y_1 之间的误差: $\text{error} = y_k - x_k$ 。

$$\text{则 } e = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ y_1 \\ y_2 \\ y_3 \end{bmatrix} - H \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix}, H = \begin{bmatrix} 1 & -1 & 0 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 1 & -1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

2. 请给出此问题下 W 的具体取值

因为最小二乘问题本质是求一个高斯分布的最大似然, 而我们的观测和输入是互相独立的, 那么他们的概率是乘积的形式合到一起。等于我们要求的"找到状态 x , 使得得到观测 z 和输入 u 的概率最大"的问题就可以分解成如下形式

$$\text{argmax} P(z, u|x) = \text{argmax} P(z|x) * P(u|x)$$

$$= \prod_{k=1}^3 p(u_k|x_k, x_{k-1}) \prod_{k=1}^3 p(u_k|x_k)$$

我们对高斯分布 $P(z|x)$ 和 $P(u|x)$ 做概率密度展开, 再取负对数, 原最大概率问题变成了对下式求最小问题。

$$\text{argmin} = \sum_{k=1}^3 e_{v,k}^T Q_k^{-1} e_{v,k} + \sum_{k=1}^3 e_{y,k}^T R_k^{-1} e_{y,k}$$

$$= \sum_{k=1}^3 (v_k - x_k + x_{k-1})^T Q_k^{-1} (v_k - x_k + x_{k-1}) + \sum_{k=1}^3 (y_k - x_k)^T R_k^{-1} (y_k - x_k)$$

第一题定义了 $e = z - Hx = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ y_1 \\ y_2 \\ y_3 \end{bmatrix} - \begin{bmatrix} 1 & -1 & 0 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 1 & -1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix}$, 可以得到 $e = \begin{bmatrix} v_1 - x_1 + x_0 \\ v_2 - x_2 + x_1 \\ v_3 - x_3 + x_2 \\ y_1 - x_1 \\ y_2 - x_2 \\ y_3 - x_3 \end{bmatrix}$

参考上面 $e^T Q_k e$ 和 $e^T R_k e$ 的设计, 易得 $W = \begin{bmatrix} Q_k & 0 \\ 0 & R_k \end{bmatrix} = \begin{bmatrix} Q_1 & 0 & 0 & 0 & 0 & 0 \\ 0 & Q_2 & 0 & 0 & 0 & 0 \\ 0 & 0 & Q_3 & 0 & 0 & 0 \\ 0 & 0 & 0 & R_1 & 0 & 0 \\ 0 & 0 & 0 & 0 & R_2 & 0 \\ 0 & 0 & 0 & 0 & 0 & R_3 \end{bmatrix}$

3. 假设所有噪声相互无关，该问题存在唯一的解吗？若有，唯一解是什么？若没有，说明理由。

有唯一解，需要 $\text{rank}(H) \geq \text{size}(X)$ 。即公式数量超过未知数数量。这个问题其实就是 $HX=Y$ 的最小二乘问题。

设 $H \in \mathbb{R}^{m \times n}, X \in \mathbb{R}^{n \times 1}$

$$\begin{aligned}HX &= Y \\f(x) &= Y - HX \\min F(x) &= \frac{1}{2} \|f(x)\|^2\end{aligned}$$

对 X 求导并令导数=0，有

$$\begin{aligned}\frac{d \min F(x)}{dx} &= \frac{d \frac{1}{2} (Y - HX)^2}{d(Y - HX)} * \frac{d(Y - HX)}{dX} = 0 \\&= (Y - HX) * (-H) = 0 \\H^T H X &= H^T Y \\X &= (H^T H)^{-1} H^T Y\end{aligned}$$